qual_by_position.py 사용법

FASTQ 파일의 모든 read에서 같은 위치(1번째 염기, 2번째 염기, …)의 품질 점수를 모아
위치별 평균을 계산하고, 위치<TAB>평균 품질 형식으로 출력하는 스크립트이다.
FastQC의 Per base sequence quality 그래프가 계산하는 평균값과 같다.

1. 실행 방법

lab11/ 폴더에서 실행한다.

```
cd lab11
# 화면에 출력
python3 src/qual_by_position.py data/SRR1553607_1.fastq
# 파일로 저장
python3 src/qual_by_position.py data/SRR1553607_1.fastq doc/qual_by_position.tsv
```

인자	설명
<FASTQ파일>	입력 FASTQ (필수, .gz 압축 파일도 가능)
[출력파일]	결과를 저장할 파일 (생략하면 화면에 출력)

2. 출력 형식

헤더 없이 한 줄에 한 위치씩, 탭으로 구분한다. 평균은 소수점 둘째 자리까지 쓴다.

```
1    32.04
2    32.17
3    32.28
...
101    28.25
```

3. 계산 원리

1. FASTQ는 4줄이 read 하나이다 (@이름 / 서열 / + / 품질 문자열).
2. 품질 문자 하나가 염기 하나의 점수이다. Phred+33 인코딩이므로 점수 = ord(문자) - 33
(예: I → 40, 5 → 20, ! → 0).
3. 위치 i마다 점수 합계와 read 수를 누적하고, 마지막에 합계 / read 수로 평균을 낸다.
4. read 길이가 달라도(트리밍 후 등) 각 위치는 그 위치까지 염기가 있는 read만으로 평균
을 낸다.
5. 파일을 4줄씩 읽으므로 큰 파일도 메모리를 많이 쓰지 않는다.

4. 오류 처리

상황	메시지	종료 코드
인자 없음	사용법: python3 src/qual_by_position.py <FASTQ파일> [출력파일]	1
파일 없음	오류: 파일을 찾을 수 없습니다: ...	2
FASTQ 형식 아님 / 서열·품질 길이 다름 / read 없음	오류: ...	3

5. 테스트 결과

(1) 손으로 계산 가능한 작은 파일 (data/test.fastq)

```
@r1  ACGT  품질 IIII  → 40 40 40 40
@r2  ACGT  품질 !!!!  →  0  0  0  0
@r3  AC    품질 5+    → 20 10
```

위치	계산	기대값	출력
1	(40+0+20)/3	20.00	20.00
2	(40+0+10)/3	16.67	16.67
3	(40+0)/2	20.00	20.00
4	(40+0)/2	20.00	20.00

길이가 다른 read(r3은 2bp)가 섞여도 3·4번 위치는 r1, r2만으로 평균을 낸다.
오류 상황 3가지(인자 없음, 파일 없음, FASTA 파일 입력)와 .gz 입력도 확인했다.

(2) 실제 데이터 data/SRR1553607_1.fastq

- read 203,445개, 모두 101bp → 위치 101개, 실행 시간 약 2초
- 1번 위치 32.04에서 올라가 14번 위치에서 최고(38.47)가 되고, 이후 read 뒤쪽으로 갈수록 낮아져 101번 위치는 28.25이다. 87번 위치부터 평균이 30 아래로 떨어진다.
- PDF 마지막 쪽에 원본과 trimmed 결과를 겹친 위치별 평균 품질 그래프를 넣었다.

(3) FastQC 결과와 비교

doc/SRR1553607_1_fastqc.zip 안의 fastqc_data.txt(Per base sequence quality의 Mean 열)와 비교했다.
FastQC는 1~9번은 위치별로, 10번 이후는 10-11, 12-13 처럼 구간으로 묶어 보여 주므로, 구간은 스크립트 값의 평균을 내어 비교했다.

위치	스크립트	FastQC
1	32.04	32.04
2	32.17	32.17
3	32.28	32.28
98-99	29.08	29.08
100-101	28.59	28.59

55개 구간 모두 일치했다(최대 차이 0.005, 소수점 반올림 차이).

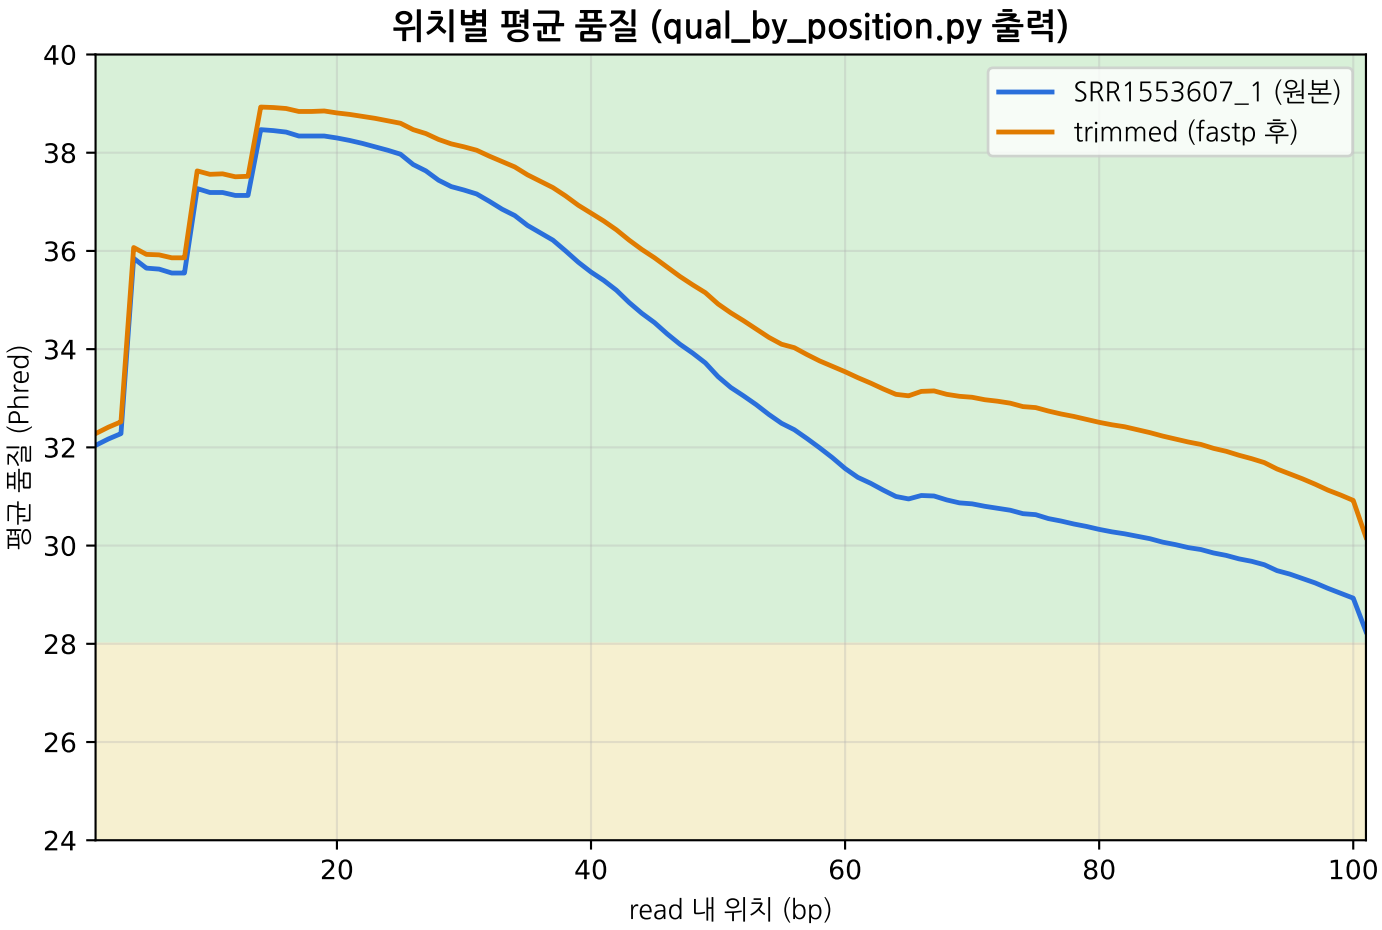
(4) 트리밍 후 데이터 data/trimmed.fastq

```
python3 src/qual_by_position.py data/trimmed.fastq doc/qual_by_position_trimmed.tsv
```

read 188,357개. fastp로 저품질 부분을 잘라내어 101번 위치 평균이 28.25 → 30.17로 올라갔다.

6. 생성 파일

파일	내용
src/qual_by_position.py	스크립트
data/test.fastq	테스트용 작은 FASTQ
doc/qual_by_position.tsv	SRR1553607_1 위치별 평균 품질
doc/qual_by_position_trimmed.tsv	trimmed 위치별 평균 품질
doc/qual_by_position.md, .pdf	이 사용법 문서



배경색: 초록 = 좋음(≥28), 노랑 = 보통(20~28) — FastQC 그래프와 같은 기준